Data story telling

Inicialmente solo quería saber y entender por qué hay tantos accidentes en mi ciudad, Buenos Aires, en comparación con otras ciudades de Argentina.

Ya que tenemos un alto número de accidentes con 15 millones de habitantes en esta ciudad. Para hacerlo utilicé el data set de la página oficial del gobierno de Buenos Aires llamado: "SeguridadVialAutopistasAUSA".

Empecé a analizar el data set haciendo gráficos en función de los accidentes ocurridos, con sus respectivos horarios y cantidad de muertes que tuvo cada accidente.

Índice

Contenido

Índice	1
Carga de data sets y pequeñas consultas	2
Visualización prolija del Data set mediante DataFrame	4
Resolviendo hipótesis	4
Cantidad de fallecidos en determinados horarios	5
Cantidad de fallecidos que fallecieron en un accidente con un camión involucrado	6
Cantidad de fallecidos en dependiendo del clima	6
Análisis para ver cómo se comportan las distribuciones de los fallecidos	7
Análisis para ver cómo se comportan las distribuciones de las horas en las queocurren los accidentes	8
Análisis para ver las horas donde el clima está en buenas condiciones paraman	-
Análisis para calcular la cantidad de accidentes y compararlo con la cantidad defallecidos y lesionados dependiendo el vehículo	/
Análisis de modelo de regresión – Volstat	11
Análisis de métricas	12
Conectar una API de incidentes de trafico	12
Data Wrangling	13
Control de datos perdidos	13
Entrenamiento y testeo	14
Método de validación cruzada	14
Optimización de hiperparámetros	15
Algaritma "Pandamizadsaarsh"	15

Carga de data sets y pequeñas consultas Intervenciones de seguridad vial

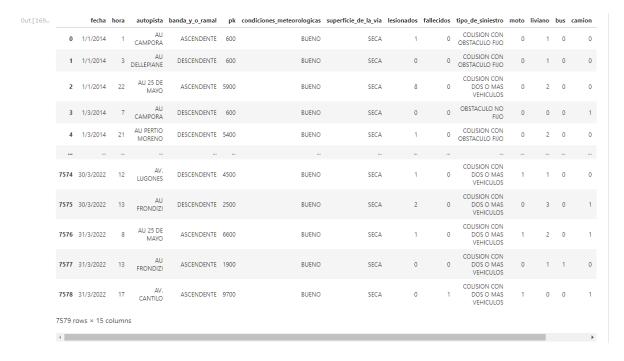
```
(7579, 15)
fecha hora
                                autopista banda_y_o_ramal
       1/1/2014
                               AU CAMPORA
                            AU DELLEPIANE
                                               DESCENDENTE
       1/1/2014
                                                               600
                   22 AU 25 DE MAYO
       1/1/2014
                                                 ASCENDENTE 5900
                   7 AU CAMPORA
21 AU PERTIO MORENO
                                               DESCENDENTE 5400
       1/3/2014
       1/3/2014
7574 30/3/2022
                                                DESCENDENTE 4500
                             AV. LUGONES
7575 30/3/2022
                              AU FRONDIZI
                                                DESCENDENTE 2500
7576 31/3/2022
                            AU 25 DE MAYO
AU FRONDIZI
                                                ASCENDENTE 6600
ASCENDENTE 1900
      31/3/2022
                   13
7578 31/3/2022
                   17
                              AV. CANTILO
                                                 ASCENDENTE 9700
      condiciones_meteorologicas superficie_de_la_via lesionados fallecidos \
                                                    SECA
SECA
                            BUENO
                            BUENO
                            BUENO
                                                    SECA
                            BUENO
                                                    SECA
                            BUENO
                                                    SECA
...
7574
                            BUENO
7575
7576
                            BUENO
BUENO
                                                    SECA
SECA
                            BUENO
7578
                            BUENO
                                                    SECA
           tipo_de_siniestro moto liviano bus camion \backslash COLISION CON OBSTACULO FIJO 0 1 0 0
            COLISION CON OBSTACULO FIJO
      COLISION CON DOS O MAS VEHICULOS
                      OBSTACULO NO FIJO
           COLISION CON OBSTACULO FIJO
                                                        2
7574 COLISION CON DOS O MAS VEHICULOS
7575 COLISION CON DOS O MAS VEHICULOS
7576 COLISION CON DOS O MAS VEHICULOS
7577 COLISION CON DOS O MAS VEHICULOS
7578 COLISION CON DOS O MAS VEHICULOS
     tipoDeVehiculo
               moto
bus
              camion
              camion
7574
                moto
7575
              camion
7576
                 bus
                moto
7578
```

[7579 rows x 15 columns]

```
Reclamos AUSA
(5659, 3)
      nro_caso
                                                   tItulo_caso \
                                RECLAMOS/VUELTO ERRONEO/FALTANTE
0
     C00126163
                  RECLAMOS/DAÑO DEL VEHICULO SOBRE AU./OBJETO
     C00126165
                         RECLAMOS/DAÑO EN VIA DE PEAJE/VIA 07 A
     C00126167
     C00126169 RECLAMOS/DAÑO DEL VEHICULO SOBRE AU./AGRESIÓN ...
     C00126171 QUEJAS/TELEPEAJE/DISPOSICIONES DE SERVICIO
5654 C00136954
5655 C00136955
5656 C00136956
                             QUEJAS/MALA ATENCION/A completar
                                 QUEJAS/EN GENERAL/A completar
                           RECLAMOS/VUELTO ERRONEO/A completar
                                      QUEJAS/PEAJE/A completar
5658 C00136958
                                 QUEJAS/EN GENERAL/A completar
0
     2016-12-01 15:47:26
     2016-12-01 16:01:31
     2016-12-01 16:13:41
     2016-12-01 16:35:22
     2016-12-01 17:15:12
5654 2019-04-20 10:00:21
5655 2019-04-20 15:00:24
5656 2019-04-22 11:00:24
5657 2019-04-23 10:30:10
5658 2019-04-23 10:30:20
[5659 rows x 3 columns]
       La cantidad total de fallecidos debido a un accidente vial es de: 72
       La cantidad maxima de fallecidos debido a un accidente vial es de: 3
    La cantidad total de fallecidos debido a un accidente vial es de: 72
    La cantidad maxima de fallecidos debido a un accidente vial es de: 3
    La media de fallecidos debido a un accidente vial es de: 0.0095
```

Acá cargue los conjuntos de datos que había descargado desde la página oficial del gobierno de la ciudad. Imprimí títulos y mostré los data sets por separado. También calcule la cantidad de fallecidos, la cantidad máxima de muertos que hubo por accidente y la media de fallecidos debido a un accidente vial.

Visualización prolija del Data set mediante DataFrame

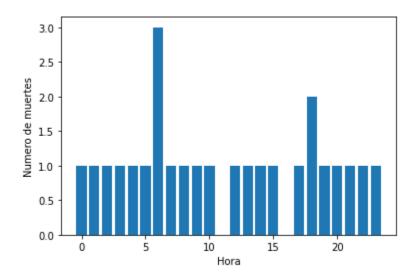


Esto simplemente lo hice para tener una mejor visualización de mi conjunto de datos.

Resolviendo hipótesis

Me plantee una serie de hipótesis, de preguntas para responder, de sucesos que se podrían o no haber evitados. En muchos de ellos llegue a una determinada conclusión, en otros, quedo una respuesta abierta y/o difícil de responder, ya que no dependían de una variable en específico, sino que eran variables que yo no podía manejar.

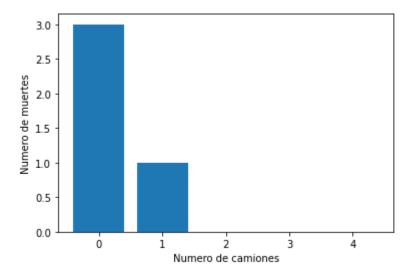
Cantidad de fallecidos en determinados horarios



Lo que me plantee en esta ocasión fue: ¿Veamos, los accidentes ocurren siempre a la misma hora? ¿Hay un patrón en cuanto al horario de accidentes? ¿Se pueden evitar más accidentes dependiendo en la hora en la que manejemos?

Mi conclusión a todas esas respuestas es que si, se puede evitar un accidente dependiendo el horario, aunque no lo crean, ya que la cantidad donde más accidentes ocurren es a la mañana, en la hora pico de la ciudad, por lo tanto, si no quieres cruzarte con algún accidente o no quieres cometer un accidente, es recomendable que salgas antes o después de esos horarios claves.

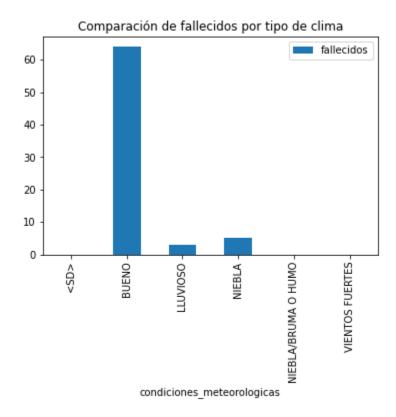
Cantidad de fallecidos que fallecieron en un accidente con un camión involucrado



Aquí analice lo siguiente: ¿Hay un patrón en cuanto al tipo de vehículo con los que se producen los accidentes de tránsito?

La respuesta que encontré en base a los datos analizados fue que no, los accidentes no dependen del tipo de vehículo, todos tenían una cantidad de accidentes bastante similar. (Puede ser que sea un poco más alto la cantidad de accidentes en moto, pero no reflejo una comparación abismal como para determinarlo como patrón)

Cantidad de fallecidos en dependiendo del clima



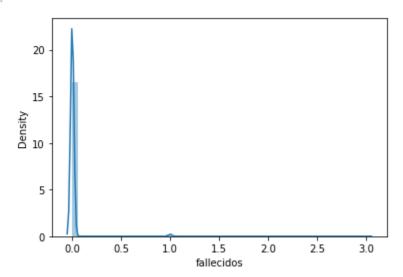
¿Hay algún patrón que me indiqué que el clima puede ser un factor fundamental para determinar si pueden ocurrir más o menos accidentes?

Esa fue la pregunta que me hice, y los datos me llevaron a esta respuesta:

Si, el patrón a analizar es la niebla, cuando hay niebla, todo empeora, los accidentes crecen exponencialmente, si esta lluvioso disminuye, pero aun, así como la calzada (autopista) esta resbalosa los accidentes siguen ocurriendo, pero hay una notable disminución de accidentes cuando el clima esta despejado y soleado.

Análisis para ver cómo se comportan las distribuciones de los fallecidos

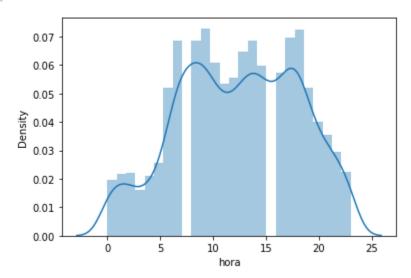
Out[12]:



Esta distribución la saque y analicé más que nada para ver cómo se comportan la cantidad de fallecidos en un accidente de tránsito por día, pude ver que la densidad es alta cuando la cantidad de fallecidos decrece, y la densidad es baja cuando la cantidad de fallecidos aumenta.

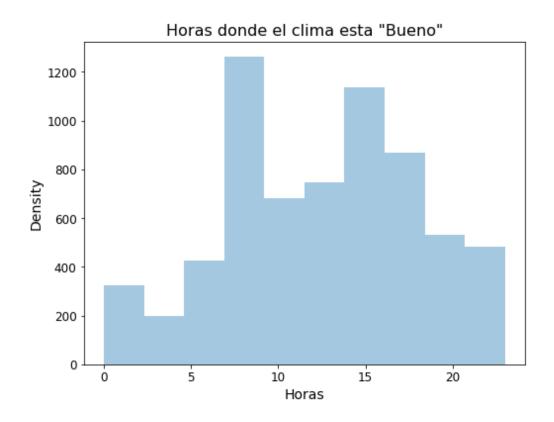
Análisis para ver cómo se comportan las distribuciones de las horas en las que ocurren los accidentes

Out[13]:



Esto lo hice con el mismo objetivo que el análisis visto anteriormente, quería ver como se manejaba la densidad en cuanto a las horas, y si, claramente aumentaba en las horas pico.

Análisis para ver las horas donde el clima está en buenas condiciones para manejar



Con la hipótesis que había analizado anteriormente, viendo los horarios y climas críticos donde más accidentes ocurrían, plantee una solución, pensando en lo opuesto analizado principalmente. Me pregunte ¿Cuáles son las horas donde el clima mayormente está en buenas condiciones para conducir?

Y esto fue un desafío y un paradigma muy difícil de resolver, ya que, en Buenos Aires, casi siempre, el clima donde esta "bueno" para conducir es justamente en los horarios pico, pero, analizando la totalidad de datos y la cantidad de accidentes que se produjeron en horarios picos y con buen clima, llegue a la conclusión de que hay clima bueno en horarios "casi picos" 1 hora o 2 horas de diferencia ya sean horas anteriores o horas posteriores para poder conducir con tranquilidad.

Análisis para calcular la cantidad de accidentes y compararlo con la cantidad de fallecidos y lesionados dependiendo el vehículo

Out[18]:		fallecidos	lesionados	moto	liviano	bus	camion	totalDeIncidentes
	0	0	1	0	1	0	0	17926
	1	0	0	0	1	0	0	17926
	2	0	8	0	2	0	0	17926
	3	0	0	0	0	0	1	17926
	4	0	1	0	2	0	0	17926

Acá utilice el método "feature selection" para analizar todas las variables, pero centrado en un objetivo en concreto, la cantidad total de accidentes, para reducir el peso en los modelos. Entonces, dependiendo del tipo de automóvil con el que se haya producido el accidente quería analizar cuantos accidentes se concretaron a lo largo de 2020 y 2021.

Análisis de modelo de regresión – Volstat

OLS Regression Results

Dep. Variable: lesi		lesionados	R-squ	ared (uncente		0.003	
Model:			Adj.	R-squared (ur	:	0.003	
Method: Least Squa			F-sta	F-statistic:			
Date:	t, 15 Oct 2022	Prob	(F-statistic)):		1.03e-06	
Time:	12:33:57	Log-L	ikelihood:			11459.	
No. Observations:		7579	AIC:			-2	.292e+04
Df Residuals:		7578	BIC:			-2	.291e+04
Df Model:		1					
Covariance Typ	e:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]	
fallecidos	0.0875	0.018	4.889	0.000	0.052	0.123	
Omnibus:				.n-Watson:		1.439	
Prob(Omnibus):		0.000	Jarqu	ıe-Bera (JB):	1	1151366.355	
Skew:		4.871	Prob(JB):		0.00	
Kurtosis:		62.591	Cond.	No.		1.00	

Notes:

- [1] R² is computed without centering (uncentered) since the model does not contain a constant.
- [2] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Acá me indica la variable que estamos analizando, en este caso la variable es "lesionados" y "fallecidos" realicé una comparación obteniendo datos como R2, coeficientes y percentiles. Viendo el R2, me doy cuenta de que el modelo no contiene un término de intersección en sí, tambiénme di cuenta de que el coeficiente de variación del modelo es bajo, está por debajo del 30%, esto quiere decir que mi modelo es **no homogéneo**, y por último, tengo los percentiles que me van a indicar como se fueron moviendo los números dependiendo de los promedios más altos y más bajos

Análisis de métricas

MAE 0.18438246010805429

El MAE me dio 0.18 (18%), este es el promedio de la diferencia absoluta entre el valor que quiero observar (el total de los fallecidos que se lesionaron) y los valores predichos (los que fallecieron andando en moto)

Conectar una API de incidentes de trafico

('girufsidition_un': 'https://pi.popsil.gov.bc.ca/jurisdition', 'un': 'https://pi.popsil.gov.bc.ca/jurisdition', 'un': 'https://pi.popsil.gov.bc.ca/jurisdition', 'un': 'https://pi.popsil.gov.bc.ca/jurisdition', 'un's 'https://pi.popsil.gov.bc.ca/jurisdition', 'status': 'ACTIVE', 'created': '2020-08-1271414136-07:09', 'undsted': '2022-08-127109'):410-7:09', 'description': 'Highway 17, in both directions personnel. Expect delays. Plan your protte ahead. Last updated Non Nar-14 at 9:19 AN PDT. (DBC-21372)', '41vr message': 'Highway 17, in both directions, Construction work between 27nd Street and 95th Street. Until Nednead y, November 30. Lane closures in both directions planned, Please slow down and watch for and obey traffic signage and personnel. Expect delays. Plan your route ahead. Last updated Monday, March 14 at 9:19 AN, 'hilmen' reference lem': -1, 'schedule': ('intervals': ['2008-08-17721147/2022-12-01707:59')], 'veent type': 'Colonit. Purity subtypes: '[1000] MAINTENMENCE'] 'sevent very': 'MINOR', 'goggraphy': ('type': 'Point', 'coordinates': -1022.09')], 'veent type': 'Colonit. Purity 'intervals': ['2008-08-17721147/2022-12-01707:59')], 'veent mes': 'Loven' Halmland Olstrict', 'id': 'drivebc.ca/JOS-18011, 'Jurisdiction', 'Un'!' 'https://api.opensil.gov.bc.ca/jurisdiction', 'u

Acá conecte una API para obtener mucha más información acerca de los accidentes de tráfico en el mundo, como, por ejemplo, cuantos accidentes hubo en USA, los modelos de auto que tienen accidentes, la severidad del accidente, el punto geográfico donde ocurrió ese accidente, el día, la velocidad y una descripción

Data Wrangling

Out[25]:		fallecidos	lesionados	moto	bus	liviano	camion
	0	0	1	0	0	1	0
	1	0	0	0	0	1	0
	2	0	8	0	0	2	0
	3	0	0	0	0	0	1
	4	0	1	0	0	2	0

Acá lo que hice fue reemplazar todos los valores NaN, para dejar el conjunto de datos limpio.

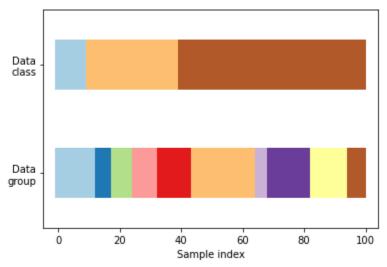
Control de datos perdidos

```
fallecidos
False 7579
Name: fallecidos, dtype: int64
lesionados
False 7579
Name: lesionados, dtype: int64
False 7579
Name: moto, dtype: int64
bus
False 7579
Name: bus, dtype: int64
liviano
False 7579
Name: liviano, dtype: int64
camion
False 7579
Name: camion, dtype: int64
```

Lo que hice acá es ver cuántos datos perdí y cuantos logre recuperar haciendo el Data Wrangling

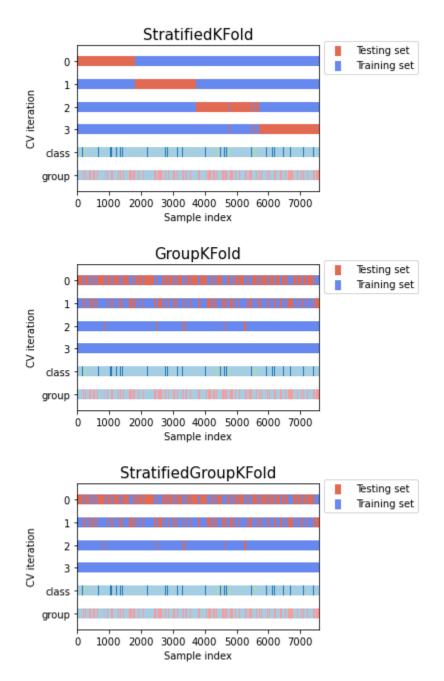
Entrenamiento y testeo

Método de validación cruzada



Acá use el método de validación cruzada de K-Fold con el objetivo de evaluar los resultados de un análisis estadístico y garantizar que son independientes de la partición entre los datos de entrenamiento y los datos de prueba.

array([0.99912049, 0.99956025, 0.99824099, 0.99868074, 0.99780123])



Observamos que los resultados son muy buenos, muy cercanos al 100%, para cada uno de los 5 folds que hemos solicitado. De esta manera podemos concluir, considerando la validación cruzada que realizamos, se ha demostrado que es muy bueno.

Optimización de hiperparámetros Algoritmo "Randomizedsearch"

Acá implementé un algoritmo de búsqueda aleatoria en hiperparámetros con el objetivo de optimizar mediante una búsqueda de validación cruzada la configuración de parámetros, y así, obtener el mejor conjunto de hiperparámetros posible.

Selección de modelos

MSE

El error cuadrático medio (MSE) de este modelo resulta ser de 1.256894049346879 Acá seleccione el modelo "MSE", que sería el error cuadrático medio.

Medí el error cuadrático de las predicciones mostradas anteriormente. Y como se puede observar, estamos frente a un modelo muy bueno ya que, mientras menor sea el número, mejor es la predicción.